

Universidad de Alcalá Escuela Politécnica Superior

GRADO EN INGENIERÍA EN ELECTRÓNICA Y
AUTOMÁTICA INDUSTRIAL

Trabajo Fin de Grado

Mejora en la predicción de viento extremo haciendo uso de
técnicas de aprendizaje de máquina.

ESCUELA POLITECNICA
SUPERIOR

Autor: Jorge Coca García

Tutor: Jorge Pérez Aracil

Cotutor: César Peláez Rodríguez

UNIVERSIDAD DE ALCALÁ
Escuela Politécnica Superior

Grado en Ingeniería Electrónica y Automática Industrial

Trabajo Fin de Grado
Mejora en la predicción de viento extremo haciendo uso de
técnicas de aprendizaje de máquina

Autor: Jorge Coca García

Tutor/es: Jorge Pérez Aracil y
César Peláez Rodríguez

TRIBUNAL:

Presidente: Sancho Salcedo Sanz

Vocal 1º: Laura María Cornejo Bueno

Vocal 2º: Jorge Pérez Aracil

FECHA: 18/09/2024

Índice de trabajo

Capítulo 1: Introducción.....	1
1.1. Motivación	1
1.2. Objetivos.....	2
Capítulo 2: Estudio teórico	3
2.1. Energía eólica.....	3
2.1.1. Aerogenerador	3
2.1.2. Curva Potencia-Velocidad.....	5
2.1.3. Importancia del viento extremo.....	6
2.2. Inteligencia artificial.....	6
2.2.1. Historia y antecedentes	7
2.2.2. Aplicaciones del Machine learning.....	8
2.2.3. Tipos de aprendizaje	9
2.2.4. Regresión por cuantiles	10
2.2.5. Implementación modelos Machine learning	12
Capítulo 3: Desarrollo	15
3.1. Recolección de los datos	15
3.2. Tratamiento de los datos	17
3.2.1. Histogramas	19
3.2.2. Correlación.....	21
3.3. División de los datos.....	25
3.4. Modelos machine learning.....	25
3.5. Validación del modelo	26
Capítulo 4: Resultados finales.....	29
4.1. Comparación gráfica de la predicción con los valores reales de viento.	29
4.1.1. Comparación para el modelo 1 entrenado usando diferentes rangos de tiempo de predicción.	30
4.1.2. Comparación para el modelo 2 entrenado usando diferentes rangos de tiempo de predicción.	32
4.1.3. Comparación entre el modelo 1 y 2 entrenado usando diferentes rangos de tiempo de predicción.	35
4.2. Métricas de error del modelo 1 y el modelo 2.....	37
4.3. Función de densidad de probabilidad y KDE	39
Capítulo 5: Conclusiones	48
Capítulo 6: Bibliografía	49

Índice de figuras

Figura 1: Partes de un aerogenerador [7].....	4
Figura 2: Curva de potencia-velocidad aerogenerador Gamesa G106/2500 [9]	5
Figura 3: Test de Turing [15].....	7
Figura 4: Tipos de aprendizaje [20].....	10
Figura 5: Workflow o flujo de trabajo que se sigue para crear un modelo de predicción	14
Figura 6: Mapa península ibérica con latitud y longitud. [25]	16
Figura 7: Base de datos de magnitud y dirección de viento.....	18
Figura 8: Histograma de la variable objetivo magnitud del viento	19
Figura 9: Histograma de variables predictoras de velocidad del viento, velocidad del viento hacia el este a 10 metros (a), velocidad del viento neutral hacia el este a 10 metros (b), velocidad del viento hacia el este a 100 metros (c), velocidad del viento hacia el norte a 10 metros (d), velocidad del viento neutral hacia el norte a 10 metros (e), velocidad del viento hacia el norte a 100 metros (f).	20
Figura 10: Histograma de variables predictoras: temperatura del punto de condensación a dos metros (a), temperatura a dos metros de altura del nivel de la tierra (b), presión atmosférica sobre la superficie media del nivel de mar (c), presión atmosférica en la superficie (d).....	21
Figura 11a: Gráficas de correlación entre variables predictoras y variable objetivo: correlación sp (a), correlación msl (b), correlación d2m (c), correlación t2m (d), correlación hcc (e) y correlación lcc (f).....	22
Figura 11b: Gráficas de correlación entre variables predictoras y variable objetivo: correlación mcc (a) y correlación tcc (b).....	23
Figura 12: Matriz de correlación de la variable objetivo y las variables de predicción.	24
Figura 13: Predicción de viento de 1 hora con el modelo 1.....	30
Figura 14: Predicción de viento de 3 horas con el modelo 1.....	31
Figura 15: Predicción de viento de 6 horas con el modelo 1.....	31
Figura 16: Predicción de viento de 12 horas con el modelo 1.	32
Figura 17: Predicción de viento de 1 hora con el modelo 2.....	33
.....	33
Figura 18: Predicción de viento de 3 horas con el modelo 2.....	33
Figura 19: Predicción de viento de 6 horas con el modelo 2.....	34
.....	34
Figura 20: Predicción de viento de 12 horas con el modelo 2.	34
Figura 21: Predicción de viento de 1 hora en el modelo 1 y 2.....	35

Figura 22: Prediccion de viento de 3 horas en el modelo 1 y 2.....	35
Figura 23: Prediccion de viento de 6 horas en el modelo 1 y 2.....	36
.....	36
Figura 23: Prediccion de viento de 12 horas en el modelo 1 y 2.	36
Figura 24: Curva de densidad de probabilidad para la muestra 200 con un intervalo de +1 hora.	40
Figura 25: Curva de densidad de probabilidad para la muestra 390 con un intervalo de +1 hora.	40
Figura 26: Curva de densidad de probabilidad para la muestra 1305 con un intervalo de +1 hora.	40
Figura 27: Curva de densidad de probabilidad para la muestra 200 con un intervalo de +3 horas.	41
Figura 28: Curva de densidad de probabilidad para la muestra 390 con un intervalo de +3 horas.	41
Figura 29: Curva de densidad de probabilidad para la muestra 1305 con un intervalo de +3 horas.	42
Figura 30: Curvas de densidad de probabilidad para las tres muestras seleccionadas con un intervalo de 6 horas (a) y con un intervalo de 12 horas (b). ...	42
Figura 31: dataframe con el valor real, valor del cuantil 50 y la probabilidad de viento extremo calculada.....	43
Figura 32: Dataframe con total casos, casos extremos y porcentaje.	44
Figura 33: Grafica de dispersión para un intervalo de tiempo de 1 hora con ecuación y coeficiente de correlación.....	45
Figura 34: Grafica de dispersión para un intervalo de tiempo de 3 horas con ecuación y coeficiente de correlación.....	45
Figura 35: Grafica de dispersión para un intervalo de tiempo de 6 horas con ecuación y coeficiente de correlación.....	46
Figura 36: Grafica de dispersión para un intervalo de tiempo de 12 horas con ecuación y coeficiente de correlación.....	46

Índice de tablas

Tabla 1: Variables predictoras	16
Tabla 2: Variables objetivo.....	17
Tabla 3: Metricas de error para el modelo 1 y 2 en un rango de 1 hora de predicción.	37
Tabla 4: Metricas de error para el modelo 1 y 2 en un rango de 3 horas de predicción.	37
Tabla 5: Metricas de error para el modelo 1 y 2 en un rango de 6 horas de predicción.	37
Tabla 6: Metricas de error para el modelo 1 y 2 en un rango de 12 horas de predicción.	37

Resumen

Este TFG se centra en la predicción de viento extremo haciendo uso de técnicas de machine learning. Para ello se lleva a cabo un análisis de datos de una base meteorológica que posteriormente se utilizará para entrenar dos modelos de regresión por cuantiles. Una vez entrenados se compararán ambos resultados y se elegirá el mejor modelo para crear un sistema de alertas que nos diga la probabilidad de viento extremo en un punto de la península ibérica para ser utilizado en la implementación con la energía eólica.

Palabras clave: Machine Learning, regresión por cuantiles, predicción de viento extremo, energía eólica.

Abstract

This final project focuses on extreme wind prediction using machine learning techniques. For this purpose, a data analysis is carried out on a meteorological database, which will later be used to train two quantile regression models. Once trained, both results will be compared, and the best model will be chosen to create an alert system that indicates the probability of extreme wind at a specific point on the Iberian Peninsula, to be used in the implementation of wind energy.

Keywords: Machine Learning, quantile regression, extreme wind prediction, wind energy.

Resumen extendido

En la actualidad se intenta conseguir el aprovechamiento del enorme potencial que suponen las energías renovables, una de las más importantes y con más aprovechamiento en la red eléctrica de España es la energía eólica.

Esta fuente de energía supone una gran alternativa a los combustibles fósiles, obteniendo grandes ventajas en ella, como el poco impacto ambiental que supone la instalación de aerogeneradores, las bajas emisiones que supone la fabricación o su bajo mantenimiento, entre otras.

Por otro lado, obtenemos una gran desventaja, que hace frenar el impulso del uso de esta energía limpia, que es, la aleatoriedad del viento extremo, esto provoca que los parques eólicos tengan que establecer medidas de seguridad para detener la generación ante cambios bruscos de viento o ante vientos extremos.

Por esto y por otros motivos la energía eólica no puede ser utilizada únicamente en la red eléctrica de un país y se tenga que disponer de otras fuentes de energía, en algunas ocasiones, contaminantes.

El objetivo de este Trabajo Fin de Grado es emplear técnicas de Machine Learning para crear un sistema de alertas de viento extremo que arroje al usuario una probabilidad de dicho evento para intervalos de 1, 3, 6 y 12 horas para así conseguir mayor facilidad de implementación de esta energía en la red eléctrica de España.

El Machine Learning pertenece a la creciente rama de la inteligencia artificial y es utilizada en numerosos campos. Esta crea modelos que entrena con una serie de datos proporcionados por el programador, estos datos están divididos entre variables predictoras y variable objetivo en el caso de este trabajo, la velocidad del viento.

Una vez entrenado el modelo, se pasa a una parte de verificación para comprobar que el modelo creado da unos resultados razonables y dependiendo de la aplicación, dar por terminado el modelo o seguir entrenándolo para mejorar sus resultados.

Por lo tanto, estas técnicas se pueden utilizar para problemas donde el ser humano no ve correlaciones en los datos que ya han ocurrido y así determinar los valores que tendrá una variable en el presente o en un rango de tiempo futuro.

Para la realización de este Trabajo Fin de Grado se ha estructurado en los siguientes capítulos:

- **Capítulo 1 Introducción:** En este capítulo se expondrá la motivación de este TFG, en este caso la integración la integración de la energía eólica a la red eléctrica utilizando modelos de machine learning. También se redacta los objetivos específicos del trabajo.
- **Capítulo 2 Estudio teórico:** En este capítulo se hará una revisión al estudio teórico n la primera parte de la energía eólica, ¿Qué es?, ¿Cómo se genera?, importancia del viento extremo, etc. Y una segunda parte revisando la teoría del machine learning, ¿Qué es?, historia, tipos de modelos, etc.
- **Capítulo 3 Desarrollo:** En este capítulo se realizarán los pasos que hay que seguir para el entrenamiento de un modelo de machine learning, desde la obtención y tratamiento de datos hasta métricas de error y graficas de comparación que se utilizarán en el capítulo 4.
- **Capítulo 4 Resultados finales:** En este capítulo se compararán los dos modelos con gráficas comparando los valores predichos y los valores reales de viento y a través de métricas de error explicadas en el capítulo anterior. Por último, se elegirá el mejor modelo y se hará un estudio a través de curvas de densidad de probabilidad a través de la estimación KDE.
- **Capítulo 5 Conclusiones:** En este capítulo se mostrarán las conclusiones que se han obtenido al realizar este TFG, profundizando en los resultados obtenidos de ambos modelos y en si el objetivo principal de este trabajo se ha cumplido o no.
- **Capítulo 6 Bibliografía:** Usada para elaboración de este TFG.

Capítulo 1

Introducción

1.1. Motivación

El sector energético es uno de los mayores causantes en la generación de gases de efecto invernadero [1]. Esto es producido por el gran uso que damos a los recursos que podemos encontrar en la naturaleza.

Los recursos no renovables son aquellos que se forman de manera muy lenta, y que no se forman de manera natural en el medio ambiente, entre ellos están el petróleo, el carbón o el gas natural. Estos recursos socialmente se llaman no renovables cuando su tasa de consumo supera la tasa de reposición o recuperación [2].

Ante este problema surge la necesidad de generar electricidad mediante energías renovables, estas fuentes de energía son limpias y abundan en nuestro planeta, son producidas de manera natural diariamente y son prácticamente infinitas, entre ellas se encuentran, la energía eólica, que porcentualmente ocupa un 23,5 % del total de la energía generada en España en el 2023 y la energía solar fotovoltaica que ocupa un 14 % [3].

En el caso de la energía eólica, esta ha sido la primera fuente de generación eléctrica en España en el año anterior, con una cobertura de demanda, como hemos dicho antes, de aproximadamente un 24 % del total. España cuenta con un total de 22.000 aerogeneradores instalados generando un total de 61.000 GWh [4].

El problema que presenta este método de generación de energía y que frena su avance, es la aleatoriedad de la velocidad del viento, esto hace que sea difícil incorporarla en el sistema eléctrico de cada país.

Los parques eólicos ante este problema proponen medidas de seguridad, tanto para cambios bruscos de viento, en los que peligra la estabilidad y el daño al aerogenerador como para también vientos extremos, en los que el aerogenerador no puede producir energía.

Ante estos problemas desde hace unos años se intenta predecir la velocidad de viento en las próximas horas, ya sea con métodos matemáticos o estadísticos como con técnicas de machine learning.

1.2. Objetivos

Este Trabajo de Fin de Grado tiene como objetivo principal entrenar modelos de Machine Learning para poder predecir, en un intervalo de tiempo máximo de 12 horas, si el viento en un cierto punto de la península ibérica va a ser extremo o no, para así poder conseguir un sistema de alertas que pueda ser usado tanto para empresas que suministren energía eólica como para que la red eléctrica de España pueda predecir la cantidad de energía que se va a poder suministrar por cada parque eólico.

Para el desarrollo de este trabajo se hará uso de librerías compatibles con Python y consistirá en 2 modelos diferentes de regresión por cuantiles, estos modelos se entrenarán con los mismos datos de un punto y sus alrededores, de la península ibérica y se compararán los resultados para diferentes intervalos de tiempo tanto con métricas de error como con gráficas comparativas.

Por último, se tiene como objetivo interpretar todos los resultados y obtener conclusiones claras de ellos, seleccionando el modelo de machine learning que se adapte mejor para el objetivo de predecir vientos extremos.

Capítulo 2

Estudio teórico

2.1. Energía eólica

La energía eólica se ha convertido en una de las fuentes de energía renovable más rentable en los últimos años, debido a los avances que ha habido en los aerogeneradores y la cantidad de viento que hay en algunas zonas del planeta. Muchos países han apostado por esta manera de obtener energía limpia.

Para poder estudiar como generamos esta energía hay que conocer el origen del viento. Los vientos se generan debido a la diferencia de presión entre dos puntos de la superficie terrestre lo que ocasiona que exista un desequilibrio de temperaturas provocando que una masa de aire caliente ascienda y ocupe el lugar de una masa de aire frío lo que provoca corrientes de aire.

Esta energía ha sido utilizada desde hace miles de años para impulsar los primeros barcos de vela o mover las hélices de los molinos. Se trata de un tipo de energía cinética que se genera a partir de las corrientes de aire y que se puede transformar en electricidad a través de un generador eléctrico [5].

2.1.1. Aerogenerador

Para poder obtener esta energía cinética que presenta el viento y convertirlo en energía eléctrica usamos los aerogeneradores, estos son estructuras de aproximadamente 50 metros, con normalmente 2-3 aspas con una longitud de 25-30 metros.

El viento incide sobre las palas del rotor, estas son diseñadas para obtener el mejor rendimiento, la velocidad de rotación está siempre limitada por la velocidad de punta de pala, cuyo límite actualmente se establece por criterios acústicos.

La multiplicadora transforma la baja velocidad del eje del rotor en alta velocidad en el eje del generador eléctrico, este elemento es muy común en aerogeneradores conectados a red, debido a que deben llevar una velocidad específica para cumplir con las especificaciones de frecuencia impuestas por la red eléctrica, en el caso de España, de 50 Hz.

La parte más importante, es el generador eléctrico, este convierte la energía mecánica del eje saliente de la multiplicadora en energía eléctrica mediante el principio de inducción electromagnética. Existen varios tipos de generador, entre ellos los más utilizados son dos: el generador de inducción síncrono de imanes permanentes que genera un campo magnético constante, eliminando así la necesidad de energía adicional para la excitación del campo, este tipo de generador es altamente eficiente.

El otro tipo de generador más usado en aerogeneradores a gran escala es el generador de inducción de doble alimentación (DFIG), estos son asíncronos y se puede extraer energía eléctrica tanto del devanador del estator como del devanado del rotor gracias a la tecnología basada en inversores bidireccionales, estos aerogeneradores presentan menos fiabilidad, pero permiten controlar el flujo de potencia bidireccionalmente entre el rotor del aerogenerador y la red eléctrica [6].




Figura 1: Partes de un aerogenerador [7].

Por último, encontramos elementos como un sistema de control, que supervisa las operaciones del aerogenerador, así como la orientación mediante un motor para obtener el mayor rendimiento dependiendo de la dirección del viento, también permite controlar el ángulo de las palas para controlar la velocidad del rotor.

El aerogenerador tiene otros elementos como una veleta y un anemómetro para obtener datos del viento como la velocidad y la dirección, también dispone de un freno para detener el rotor en condiciones de emergencia por viento extremo o en labores de mantenimiento.

2.1.2. Curva Potencia-Velocidad

La velocidad del viento determina la cantidad de energía que generará el aerogenerador, no obstante, no se cumple que cuanto más velocidad de viento haya más potencia se generará, esta relación entre potencia y velocidad viene representada por la curva P-V y normalmente la dan los fabricantes de los aerogeneradores a las compañías eólicas.

Las turbinas son diseñadas para trabajar dentro de unos límites de velocidad, para iniciar la generación es necesario que este alcance una velocidad mínima que suele empezar entre los 3 m/s y los 4 m/s dependiendo del aerogenerador, velocidad llamada «cut-in speed» y que no supere entre los 24 m/s y los 25 m/s de velocidad máxima, llamada «cut-out speed» [8].




Figura 2: Curva de potencia-velocidad aerogenerador Gamesa G106/2500 [9].

En la figura 2 podemos observar la curva de potencia-velocidad del aerogenerador G106/2500, fabricante Gamesa, en el que podemos observar 3 zonas, la primera en la que la potencia aumenta a desde la velocidad de cut-in (3 m/s) hasta los 12 m/s, posteriormente nos encontramos una zona donde la potencia se mantiene máxima y constante, y finalmente nos encontramos una zona donde la potencia se reduce y finalmente, en el cut-out speed (24 m/s) se corta la generación de energía.

Este límite de velocidad máxima lo indica el fabricante para aumentar la vida útil y la seguridad de los componentes del aerogenerador.

2.1.3. Importancia del viento extremo

Todas las empresas de suministro de energía eólica presentan un problema común, la aleatoriedad del viento, en particular, de los vientos extremos.

La capacidad de predecir estos eventos es crucial para la implementación de esta energía renovable al sistema de red eléctrica de España, además permite mejorar la seguridad y la eficiencia de los aerogeneradores, nos permite conocer el momento perfecto para cortar el suministro o para realizar tareas de mantenimiento sin perjudicar las ganancias de las compañías eléctricas.

Para poder impulsar este método de generación de energía se estudian modelos de machine learning que nos permita conocer en un periodo de tiempo corto la velocidad del viento para así poder conocer la cantidad de watios que se podrán producir en cada parque eólico.

2.2. Inteligencia artificial.

La inteligencia artificial (IA) es un campo de la informática que se enfoca en crear sistemas que puedan realizar tareas que normalmente requieren un ser humano, como el aprendizaje, el razonamiento y la percepción [10].

Al otorgar estas funciones a una maquina esta es capaz de adquirir funciones imposibles para el ser humano, como procesamiento de grandes bases de datos a una gran velocidad y sin interrupción. La finalidad de la inteligencia artificial en este trabajo es crear modelos de machine learning para predecir viento extremo.

El Machine Learning o aprendizaje automático es una rama de la inteligencia artificial antes mencionada que dota a los ordenadores de la capacidad de identificar patrones en datos masivos y elaborar predicciones [11], estos ordenadores una vez programados son capaces de realizar tareas específicas de manera autónoma, es decir, sin necesidad de un ser humano.

El ordenador crea un modelo que funciona gracias a instrucciones matemáticas llamadas algoritmos, estos a su vez se crean con una primera fase de entrenamiento, en el que el programador introduce una serie de variables, en el caso de la predicción, hay dos tipos de variables, las variables predictoras y la variable o variables objetivos, las que el modelo posteriormente predecirá. El modelo obtendrá en los datos de entrenamiento patrones que se repiten, así irá aprendiendo que cuando sucedan unos valores específicos de las variables predictoras, la variable objetivo tomará un valor concreto.

Una vez realizada la tarea de entrenamiento, se pasa al testeo, en el que ahora el modelo, ya entrenado, coge las variables predictoras e intenta adivinar sin conocer la variable objetivo que valor tiene esta, graficando este valor predicho y el valor real de la variable objetivo y con métricas de error que explicaré más adelante podemos determinar si el modelo es bueno en su aplicación o no.

2.2.1. Historia y antecedentes

Para conocer lo que es el machine learning nos tendremos que ir a su comienzo, este es en 1943, cuando el matemático Walter Pitts y el neurofisiólogo Warren McCulloch dieron a conocer su trabajo que intentaba mapear matemáticamente el pensamiento y la toma de decisiones de los seres humanos [12]. Esta rama de estudio sería un preámbulo de lo que hoy en día se conoce como inteligencia artificial.

En el 1950 un científico llamado Alan Mathison Turing creo el “Test de Turing”, cuya finalidad era medir que tan inteligente podía ser una computadora [13]. Esta prueba consiste en que una persona interactúa con una maquina y con otra persona a través de un teclado y una pantalla de manera aislada. Si la persona no puede distinguir si está hablando con una persona o con la maquina se considera que la maquina ha pasado la prueba de Turing [14].

Esta prueba se utiliza como un estándar de medida para la inteligencia artificial y la capacidad de una máquina para realizar tareas que requieren inteligencia humana, como el procesamiento de lenguaje natural, la toma de decisiones, el razonamiento y la creatividad [14].




Figura 3: Test de Turing [15].

Unos años más tarde, en el 1952 se creó el primer programa capaz de aprender, creado por el informático Arthur Samuel, este software era capaz de jugar damas, almacenar información y estilos de juego de las partidas realizadas lo que hacía que cada vez fuera mejor [13].

Debido a la falta de capital, estos proyectos de inteligencia artificial no siguieron progresando hasta la década de los 70, donde en el 1979 unos estudiantes de ingeniería de la universidad de Stanford crearon un robot llamado “Stanford Car” capaz de desplazarse por una habitación sorteando los obstáculos de ella, esto fue capaz al algoritmo de Nearest Neighbor. [13]. Este algoritmo dio origen al machine learning, pudiendo dar a la maquina la capacidad de observar patrones y aprender de ellos para luego posteriormente adelantarse a una respuesta, esto impulso el estudio de esta tecnología tanto por universidades como por empresas privadas.

El ascenso del machine learning a la cúspide, no fue hasta 2006, cuando grandes empresas como IBM y Microsoft invertirían grandes cantidades de dinero en el desarrollo de esta tecnología.

Al año siguiente, Jeff Dean y Andrew N se asociarían para dirigir un proyecto de Google llamado Google Brain, que consistiría en una red neuronal para que Google pueda detectar patrones en videos e imágenes, esta Red Neuronal Profunda (RNP) se consolidaría a ser una de las grandes maravillas del machine learning al ser aplicada posteriormente en sistemas de seguridad, con esta tecnología además empresas como Facebook desarrollaría algoritmos más complejos como el DeepFace, el cual permitía reconocer la cara de personas como lo haría un ser humano [13].

Con la participación de estas grandes empresas se ganaría la gran reputación con la que actualmente cuenta la inteligencia artificial, hasta el punto de que Elon Musk y otro conjunto de personas fundan en el 2015 una organización sin ánimo de lucro llamada Open AI [13], siendo actualmente una de las empresas más conocidas del sector por sus avances en chatbots con ChatGPT o IA generativa como DALL E.

Así es como ha ido evolucionando la inteligencia artificial hasta el día de hoy, estando no solo presente en grandes empresas que contienen numerosos datos, si no en particulares que utilizan esta herramienta para aumentar su productividad y facilitar su vida.

2.2.2. Aplicaciones del Machine learning

El Machine learning actualmente se utiliza para diferentes aplicaciones generales, estas son algunas de las más importantes:

- **Visión artificial:** se encarga principalmente del reconocimiento de objetos e imágenes para así poder interpretarlas, es utilizada en la industria para por ejemplo automatizar procesos o para vehículos autónomos

- **Predicción:** este método es capaz estudiar grandes bases de datos y buscar en ella patrones para así poder predecir cualquier variable en un periodo de tiempo. Se utiliza principalmente en la industria, así como en medicina o en meteorología.
- **Análisis semántico, procesamiento de lenguaje natural y recuperación de información:** el análisis semántico nos permite procesar las relaciones de estructuras sintácticas de párrafos, oraciones y palabras. El procesamiento de lenguaje natural nos permite programar ordenadores para procesar datos del lenguaje de un ser humano para su posterior interpretación. Por último, la recuperación de información nos permite buscar en documentos y en bases de datos [17].

2.2.3. Tipos de aprendizaje

Para que un modelo sea creado este debe aprender de un conjunto de datos, hay diferentes maneras de aprendizaje que se pueden simplificar en estos 4:

- **Aprendizaje supervisado:** este tipo se utiliza cuando existen conjuntos de datos etiquetados, es decir que son datos reales, este conjunto de datos incluyen entradas y salidas que permiten al modelo aprender. El algoritmo mide su precisión a través de la función de pérdida, ajustando hasta que el error se haya minimizado lo máximo posible [18]. Se dividen en dos subgrupos: clasificación con el objetivo de predecir las etiquetas de clase categóricas de nuevos registros, con base en observaciones pasadas [19]. El otro subtipo es la regresión, este se trata del proceso estadístico predictivo en el que el modelo intenta predecir un valor continuo mediante la relación entre variables dependientes e independientes. Es decir, se encuentra una ecuación en la que se sustituye los valores de las variables y como resultado se obtiene el valor a predecir [19].
- **Aprendizaje no supervisado:** en este caso tenemos datos que no han sido etiquetados, por tanto, el modelo intenta buscar patrones o estructuras solo con los datos introducidos en la entrada. Existen dos subtipos, el clustering o agrupación que definen una métrica de similitud o distancia que les sirve para comparar datos. El otro subtipo es la reducción de dimensionalidad, que se utiliza para reducir el tiempo de entrenamiento de los modelos, mejorar su rendimiento o agilizar la representación visual de los datos [20].
- **Aprendizaje semi-supervisado:** este método es una mezcla de los dos tipos explicados antes, entrenando el modelo primero con una pequeña cantidad de datos etiquetados y posteriormente entrenar el modelo con una gran cantidad de modelos no etiquetados. Este método se utiliza principalmente en situaciones en las que obtener una cantidad suficiente de datos etiquetados es difícil o costoso [21].

- Aprendizaje por refuerzo: este tipo de aprendizaje se basa en problemas no supervisados que reciben refuerzos, por tanto, recompensamos los comportamientos deseados y penalizamos los no deseados, es decir, el algoritmo aprende a base de prueba y error para así maximizar la fiabilidad del modelo.

En la figura 4 podemos ver un breve resumen de las técnicas de aprendizaje explicadas.




Figura 4: Tipos de aprendizaje [20].

2.2.4. Regresión por cuantiles

En este trabajo de fin de grado se han entrenado dos modelos diferentes, ambos se han llevado a cabo mediante regresión cuantílica, a continuación, explicaré que es este tipo de regresión y posteriormente haré un breve resumen de las dos diferentes librerías utilizadas para entrenar los modelos, explicando posteriormente en el capítulo 3 como se han implementado.

La regresión cuantílica es una extensión de la regresión lineal que nos permite realizar diferentes modelos para diferentes cuantiles, mientras que la regresión lineal se centra en estimar la media convencional, el análisis por regresión cuantílica nos permite estimar la mediana (con un cuantil 0,5) u otros cuantiles como el 0,9 o 0,1.

La regresión cuantílica estudia la relación entre la variable independiente

$X = [x_1, x_2, \dots, x_n]$ y el cuantil condicional de la variable dependiente $Y = [y_1, y_2, \dots, y_n]$ [22]. La variable dependiente en nuestro caso es la velocidad del viento, y las variables independientes se verán en el capítulo 3 en más detalle.

El análisis tradicional de regresión solo puede obtener la tendencia central de la variable dependiente mientras que la regresión cuantílica puede inferir además la distribución de probabilidad condicional de la variable dependiente [23], esto se consigue entrenando tantos

modelos como la aplicación necesite, estos modelos se entrenan con diferentes cuantiles, en nuestro caso 100 modelos, desde el cuantil 0 al cuantil 1 (0.01,0.1, ...,0.5, ...,0.9, ...,1). Los cuantiles son puntos que dividen la distribución de una variable en diferentes segmentos.

El modelo de regresión cuantílica [23] es el siguiente:

$$Q_{y_t}(\tau|x_t) = f(x_t, \beta(\tau)) \quad (2.1)$$

donde $Q_{y_t}(\tau|x_t)$ es la condición τ -esimo cuantílica de la variable dependiente y_t y $\tau \in (0,1)$, el valor estimado $\hat{\beta}(\tau)$ de $\beta(\tau)$ se puede obtener minimizando la función de pérdida L:

$$\hat{\beta} = \arg \min(L); \quad L = \sum_{t=1}^n \varphi_{\tau}(y_t - x_t \beta(\tau)) \quad (2.2)$$

donde $\varphi_{\tau}(u)$ es una función asimétrica cuya formula es la siguiente:

$$\varphi_{\tau}(u) = \begin{cases} \tau u & u \geq 0 \\ (\tau - 1) u & u < 0 \end{cases} \quad (2.3)$$

Por tanto, la condición τ -esimo cuantílica de y_t puede ser estimada por el modelo lineal de regresión, de la siguiente manera:

$$\hat{Q}_{y_t}(\tau|x_t) = x_t \hat{\beta}(\tau) \quad (2.4)$$

El primer modelo ha sido entrenado usando la biblioteca de LightGBM, esta está basada en el método ‘boosting’, desarrollado originalmente por Microsoft, esta biblioteca es usado normalmente para tareas de clasificación y regresión estándar, aunque en este caso lo usaremos para la regresión cuantílica.

El objetivo principal del “Gradient Boosting” usado en LGBM es construir un conjunto de árboles de decisión que se entrenan secuencialmente, haciendo que cada árbol entrenado corrija al anterior, esto se llama boosting.

El LGBM se caracteriza por su gran eficiencia, optimizado para manejar grandes conjuntos de datos de manera rápido, esto es algo a tener en cuenta para la aplicación de predicción que estamos tratando en este trabajo.

El segundo modelo se ha entrenado usando la librería scikit-learn, usada em aprendizaje automático para tareas como clasificación, regresión o procesamiento de datos, entre otras. Está construida sobre bibliotecas como NumPy o matplotlib.

En nuestro caso haremos uso del algoritmo de Gradient Boosting Regressor, algoritmo que combina varios árboles de decisión para crear un modelo de predicción más potente, como hemos comentado antes, haremos uso de regresión por cuantiles, esto a través de la librería scikit-learn se consigue personalizando la función de pérdida, es decir, en vez de minimizar el error cuadrático medio, usaremos la pérdida por cuantiles, penalizando los errores de predicción según el cuantil objetivo, este tipo de herramientas se utiliza normalmente en tareas de predicción meteorológica o financiera.

2.2.5. Implementación modelos Machine learning

Este apartado consistirá en los pasos que hay que seguir para implementar un modelo de machine learning, hay que tener en cuenta que no solo tenemos que elegir el tipo de tecnología que vamos a utilizar para entrenar el modelo, sino que hay que preparar los datos para que el modelo los pueda interpretar, esta serie de pasos que a continuación se hará un breve resumen son los que se seguirán en el capítulo 3 de desarrollo de los modelos.

- Recolección de los datos

Este apartado consiste en recolectar los datos que posteriormente el modelo usará para entrenarse, esto conlleva elegir las variables que tengan más relevancia en nuestro trabajo. Estas bases de datos se pueden encontrar por internet, ya sea de manera gratuita o comprándolas, en nuestro caso, las bases de datos de variables meteorológicas son normalmente gratuitas y accesibles para todo el mundo.

- Tratamiento de los datos

Una vez recolectado los datos, estos se tienen que depurar, lo primero que haremos es pasarlos a un formato compatible para el entrenamiento, seleccionaremos los datos a estudiar y eliminaremos los demás y por último prepararemos los datos para ser introducidos, esto consiste en calcular otras variables a través de otras, en nuestro caso deberemos calcular la velocidad del viento y la dirección a través de dos vectores de la base de datos.

En este apartado también es interesante estudiar cada variable, para comprobar que no hay datos erróneos, así como estudiar la correlación que existe entre variables.

- División de los datos

Una vez tenemos los datos filtrados, tenemos que dividirlos, empezaremos dividiendo la variable objetivo de las variables predictoras, posteriormente se realizará un desplazamiento de un rango de horas determinado y finalmente se dividirá la base de datos

en entrenamiento, que ocupará aproximadamente un 70% y validación, que ocupará el 30% restante.

- **Elección del modelo**

En esta parte se estudiarán los diferentes modelos y se elegirá el que se pueda ajustar mejor a la aplicación de este trabajo. Esta programación se realizará en Python a través de librerías que serán explicadas en el capítulo 3.

- **Entrenamiento del modelo**

En esta parte, una vez elegido el modelo que se ajuste a las características del trabajo, se entrenará el modelo, esto conlleva ajustar parámetros de las librerías a usar para así conseguir los mejores resultados.

- **Validación del modelo**

En esta parte se usa el 30% de datos restantes para comprobar que el modelo entrenado es correcto, para ello contaremos con dos métodos, uno menos fiable pero más visual, que consistirá en gráficas de los resultados. Por otro lado, se evaluarán los resultados mediante métricas de error, con esto podremos ver de una manera más analítica que modelo entrenado obtiene mejores resultados. Si llegados a este punto vemos que ningún modelo cumple nuestras expectativas podremos volver a la parte de entrenamiento e introducir más datos de entrenamiento o cambiar algún parámetro del modelo.




Figura 5: Workflow o flujo de trabajo que se sigue para crear un modelo de predicción

Capítulo 3

Desarrollo

En este capítulo se redactará el desarrollo que se ha seguido para completar el estudio de mejora en la predicción de viento extremo, se explicará cómo se han conseguido los datos, su análisis, se estudiarán las variables utilizadas para la predicción, así como las correlaciones entre ellas, como se han implementado las diferentes bibliotecas, por último, se entrenarán los modelos y se explicarán las validaciones que se han seguido para comparar los diferentes modelos entrenados. Los resultados obtenidos se mostrarán posteriormente en el capítulo 4.

3.1. Recolección de los datos

Los datos utilizados han sido obtenidos de la base de datos “ERA5 hourly data on single levels from 1940 to present”, proyecto de reanálisis de ECMWF, que almacena datos de ocho décadas, desde el 1940 a la actualidad. La base de datos se puede descargar desde la página del programa Copernicus en [24].

ERA5 proporciona estimaciones por hora para todo el globo terráqueo, tanto superficies acuáticas como terrestres. Estos datos son obtenidos de diferentes estaciones de meteorología y mediciones mediante satélites meteorológicos. En la base de datos a parte de variables meteorológicas, se calculan medias y medianas mensuales y anuales. Cuenta con una resolución en rejilla siguiendo una cuadrícula regular de 0.25 grados para el reanálisis.

La base de datos que se ha descargado es del territorio español, con los límites exactos de latitud y longitud siguientes, ambas con intervalos de 0.25.

- Latitud (50, ..., 35)

- Longitud $(-10, \dots, 5)$

Para este estudio se ha cogido un punto exacto de la península ibérica, este punto corresponde a latitud 41 y longitud -1.




Figura 6: Mapa península ibérica con latitud y longitud [25].

Las variables que se han descargado para el estudio se ven en las siguientes dos tablas, empezando con las variables predictoras, y la segunda tabla con las variables objetivo.

Nº	Símbolo	Variable	Unidades
1	d2m	Temperatura del punto de condensación a dos metros	K
2	t2m	Temperatura a dos metros de altura del nivel de la tierra	K
3	sp	Presión atmosférica en la superficie	Pa
4	msl	Presión atmosférica sobre la superficie media del nivel del mar	Pa
5	hcc	La proporción de una cierta área cubierta por nubes que se encuentran en los niveles altos de la troposfera	Adimensional
6	mcc	La proporción de una cierta área cubierta por nubes que se encuentran en los niveles medios de la troposfera	Adimensional
7	lcc	La proporción de una cierta área cubierta por nubes que se encuentran en los niveles bajos de la troposfera	Adimensional
8	tcc	La proporción de una cierta área cubierta por nubes en todos los niveles de la troposfera	Adimensional

Tabla 1: Variables predictoras

La variable objetivo, en este caso, el viento se divide en dos componentes, una la velocidad del viento hacia el este, y otra la velocidad del viento hacia el norte.

Nº	Símbolo	Variable	Unidades
1	u100	Velocidad del viento hacia el este a 100 metros	$m s^{-1}$
2	v100	Velocidad del viento hacia el norte a 100 metros	$m s^{-1}$
3	u10	Velocidad del viento hacia el este a 10 metros	$m s^{-1}$
4	v10	Velocidad del viento hacia el norte a 10 metros	$m s^{-1}$
5	u10n	Velocidad del “viento neutral” ¹ hacia el este a 10 metros	$m s^{-1}$
6	v10n	Velocidad del “viento neutral” hacia el norte a 10 metros	$m s^{-1}$

Tabla 2: Variables objetivo

3.2. Tratamiento de los datos

Antes de comenzar con el entrenamiento de los diferentes modelos, tendremos que tratar los datos para que sean compatibles. Lo primero de todo, descarga la base de datos desde el año 2010 hasta al año 2023, esto se ha hecho en un formato .grib que es un tipo de archivo binario usado en datos meteorológicos, se utiliza principalmente para datos cuadrículados.

El archivo que se descarga es una base de datos con cada año descargado, pongamos el ejemplo de 2010, esta base de datos tendrá 3 dimensiones diferentes, el tiempo que irá desde el 01-01-2010 hasta el 31-12-2023, la latitud y la longitud de la península ibérica antes mencionada. Estos cuentan con una muestra de cada variable para cada hora dentro del intervalo antes comentado.

Para poder manipular los datos más fácil y rápidamente, el primer paso a seguir en el código será pasar del formato .grib al formato .nc, este archivo es muy utilizado en el ámbito científico para variables multidimensionales.

Una vez cambiado el formato, uniremos los datos de manera ordenada, es decir, cronológicamente, formando así una base de datos con todas las variables predictoras.

En cuanto a la variable objetivo, hemos descargado dos componentes de cada una, podemos simplificarla como dos vectores en el plano x e y, para poder tratar eso y conocer la velocidad

¹ Viento neutral: Viento que se calcula a partir del esfuerzo cortante en la superficie y la longitud de rugosidad correspondiente, asumiendo que el aire está estratificado de manera neutral.

del viento tenemos que sacar el módulo y la dirección de cada punto de la península. Como hemos visto antes, tenemos 3 diferentes tipos de datos de la velocidad de viento, para este trabajo se ha utilizado la velocidad a 100 metros, es decir, las variables 1 y 2 de la tabla 2, esto es así ya que como hemos centrado este trabajo a la energía eólica, nos conviene saber la velocidad que va a haber a la altura aproximada del aerogenerador. Las fórmulas que se han utilizado para obtener la magnitud y la dirección de la velocidad del viento son las siguientes:

$$wind_{magnitudo} = \sqrt{(u100^2 + v100^2)} \quad (3.1)$$

siendo u100 y v100 las variables 1 y 2 de la tabla 2.

$$wind_{direction} = \frac{\pi}{2} \cdot \arctan2(v100, u100) \quad (3.2)$$

siendo arctan2 el arcotangente de dos argumentos devolviendo el ángulo entre el eje x positivo y la recta que conecta el origen con un punto de coordenadas (x, y) $\neq (0,0)$ del plano euclidiano, expresado en radianes [26].

```

xarray.Dataset
Dimensions: (time: 122712, latitude: 61, longitude: 61)
Coordinates:
  number      0              int32 ...
  time        (time)         datetime64[ns] 2010-01-01 ... 2023-12-31T23:00:00
  step        0              timedelta64[ns] ...
  surface     0              float64 ...
  latitude    (latitude)     float64 50.0 49.75 49.5 ... 35.5 35.25 35.0
  longitude   (longitude)    float64 -10.0 -9.75 -9.5 ... 4.5 4.75 5.0
Data variables:
  wind_magnitude (time, latitude, longitude) float32 ...
  wind_direction (time, latitude, longitude) float32 ...
    
```

Figura 7: Base de datos de magnitud y dirección de viento

Como podemos observar en la figura 6, la base de datos cuenta con los datos desde principios de 2010 hasta finales de 2023 (time), cuenta con latitudes desde la 50 hasta la 35 (latitude) y longitudes desde la -10 hasta la 5 (longitude). Por otro lado, contamos con dos

variables, “wind_magnitude” calculada con la fórmula 3.1 y “wind_direction” calculada con la fórmula 3.2.

Posteriormente se seleccionará el punto de la península que se querrá estudiar y se creará una nueva base de datos con la variable objetivo (wind_magnitude) y las variables predictoras en el punto seleccionado y los 8 puntos alrededor.

3.2.1. Histogramas

Un histograma es una herramienta para graficar con bloques como se distribuye una variable, permiten conocer la distribución, la concentración de los datos y valores atípicos, para así comparar las diferentes distribuciones de otras variables.

La superficie de cada bloque representa la frecuencia con la cual cada variable se repite durante el periodo de tiempo establecido anteriormente. En nuestro caso conocer la distribución de cada variable es útil, en especial la variable objetivo, para conocer la velocidad media del punto de la península seleccionado.

Otra utilidad que le damos al representar los histogramas es conocer si hay algún valor fuera de lo común, es decir, que no concuerde con los valores normales. Ante esto se eliminaría ese valor, ya que se trataría de un fallo de medición proveniente de la base de datos descargada.

Hay que recordar que cada uno de los histogramas siguientes se han graficado con los valores de cada variable para el punto de la península seleccionado anteriormente.




Figura 8: Histograma de la variable objetivo magnitud del viento

Como variables predictoras también se han añadido las variables de viento a diferentes alturas, para así conseguir un mejor resultado en ambos modelos.




Figura 9: Histograma de variables predictoras de velocidad del viento, velocidad del viento hacia el este a 10 metros (a), velocidad del viento neutral hacia el este a 10 metros (b), velocidad del viento hacia el este a 100 metros (c), velocidad del viento hacia el norte a 10 metros (d), velocidad del viento neutral hacia el norte a 10 metros (e), velocidad del viento hacia el norte a 100 metros (f).




Figura 10: Histograma de variables predictoras: temperatura del punto de condensación a dos metros (a), temperatura a dos metros de altura del nivel de la tierra (b), presión atmosférica sobre la superficie media del nivel de mar (c), presión atmosférica en la superficie (d).

Como podemos observar, faltan histogramas de las variables predictoras número 5, 6, 7 y 8 de la tabla 1, el motivo por el cual estos histogramas no se han añadido a la figura 9, es debido a que las variables presentan valores muy cercanos al 0 y estos no se repiten con frecuencia, causando que el histograma no se obtenga correctamente.

3.2.2. Correlación

La correlación permite cuantificar la relación que hay entre dos variables distintas y de manera estadística medir el grado y la dirección de la relación entre las dos variables para así poder encontrar patrones entre ellas y en nuestro caso, facilitar la predicción.




Figura 11a: Gráficas de correlación entre variables predictoras y variable objetivo: correlación sp (a), correlación msl (b), correlación d2m (c), correlación t2m (d), correlación hcc (e) y correlación lcc (f).




Figura 11b: Gráficas de correlación entre variables predictoras y variable objetivo: correlación mcc (a) y correlación tcc (b).

Como podíamos esperar estas variables no presentan una correlación lineal con la magnitud del viento, sino una relación más compleja. A ojos del ser humano es imposible encontrar patrones en estas gráficas y por tanto imposible de hacer predicciones precisas sobre la velocidad del viento. Como solución a este problema se entrenará el modelo de machine learning, que será capaz de encontrar estos patrones en las variables para así poder predecir la velocidad del viento.

Un estudio interesante de hacer con la correlación es obtener su matriz, con esto tal vez podemos encontrar alguna correlación entre diferentes variables para así posteriormente poder realizar una predicción más precisa. Esta matriz permite relacionar las diferentes variables utilizando el coeficiente Pearson.

El coeficiente Pearson es una medida estadística que indica la relación entre dos variables, es decir, trata de cuantificar la dependencia lineal entre dos variables aleatorias cuantitativas. El valor del índice de correlación de Pearson está entre -1 y +1 y se calcula dividiendo la covarianza de ambas variables por la raíz cuadrada del producto de sus varianzas [28].

$$r_{XY} = \frac{\sigma_{XY}}{\sqrt{\sigma_X \cdot \sigma_Y}}$$

Donde σ_{XY} es la covarianza de ambas variables y $\sigma_X \cdot \sigma_Y$ es el producto de las varianzas de cada variable. r_{XY} es el coeficiente de Pearson que como hemos comentado antes puede tomar valores entre -1 y +1, donde -1 indica una correlación positiva perfecta, 0 indica una ausencia de correlación y 1 indica una correlación positiva perfecta.

A continuación, se mostrará la matriz de correlación con las variables de predicción y la variable objetivo.




Figura 12: Matriz de correlación de la variable objetivo y las variables de predicción.

Como podemos observar solo se han introducido en la matriz de correlación aquellas variables de predicción que fuesen del punto de estudio y no las variables de los puntos de alrededor.

Al analizar la matriz de correlación podemos observar que variables de predicción están más relacionadas con la variable objetivo y cuáles son las que tienen menos impacto. En primer lugar, vemos correlaciones positivas moderadas con las variables relacionadas con la proporción de un área con nubes a una baja media y total altura de la troposfera (lcc, mcc y tcc) con coeficientes de 0.29, 0.12 y 0.17 respectivamente. También presenta una correlación positiva pero cerca del cero la variable de la proporción de un área con nubes a una alta altura de la troposfera (hcc) con un coeficiente de 0.015, este valor tan cerca del

cero nos indica que esta variable no está correlacionada con la magnitud del viento, es decir, si la variable objetivo varía, hcc no variará prácticamente nada.

Por otro lado, obtenemos una correlación negativa en las variables de temperatura (d2m y t2m) y en las variables de presión (sp y msl) significando que si aumenta la magnitud del viento disminuyen estas variables.

3.3. División de los datos

Para poder entrenar el modelo correctamente, la base de datos tiene que estar ordenada y dividida. Lo primero que se ha realizado es dividir la base de datos en variables predictoras y variable objetivo, en las variables predictoras mencionadas en la tabla 1 se han añadido algunas variables de la tabla 2, como por ejemplo la velocidad del viento a 10 metros, esto lo hacemos para dotar al modelo de más datos relevantes y así conseguir una mejor predicción.

En cuanto a la variable objetivo (target), se ha cogido la magnitud de la velocidad del viento a 100 metros calculada con la formula (3.1) y se ha realizado un shift² con el intervalo de tiempo que se quiere predecir, es decir 1 hora, 3 horas, 6 horas y 12 horas de predicción.

A la hora de crear el modelo, una parte muy importante es definir el porcentaje de datos que emplearemos en el entrenamiento y que porcentaje se empleará en la verificación. En este caso usaremos el 70 % de los datos para el entrenamiento y el 30 % de los datos restantes para la verificación. Este porcentaje se fue cambiando durante el desarrollo del tfg hasta conseguir los mejores resultados.

3.4. Modelos machine learning

Como se ha comentado en el punto 2.2.4 se han utilizado dos modelos diferentes, con dos librerías diferentes, en el punto mencionado se comentó brevemente en qué consistía cada librería, pero en este punto profundizaré como se ha llevado el entrenamiento y que parámetros se han utilizado en cada modelo entrenado.

- **Light gradient-boosting machine (LGBM):** como hemos comentado antes, se han entrenado 100 modelos diferentes para los diferentes cuantiles, esto proporciona una estimación completa de incertidumbre de la predicción de viento extremo. Cada uno de los

² Shift: Acción de desplazar los valores de una columna en una base de datos hacia adelante o hacia atrás en el tiempo

modelos se han entrado siguiendo la tecnología de gradient boosting. Lo primero de todo ha sido dividir los datos en los porcentajes mencionados en el punto anterior (3.3), esto se ha realizado usando “train_test_split”. Para el entrenamiento se ha usado la función “LGBMRegressor” usando los siguientes parámetros: “objective = quantile” donde el modelo predice cuantiles específicos en lugar de valores promedios, “Alpha = tau” donde tau es el valor del cuantil a entrenar, “n_estimators = 100” define el número de árboles o iteraciones en el modelo, “random_state = 42” este parámetro se utiliza en muchos algoritmos de machine learning y su objetivo principal es que los resultados sean reproducibles, en este caso se modifica el valor predeterminado al valor 42.

- **Gradiente boosting regressor (Scikit-learn):** esta librería entra dentro de la biblioteca de scikit-learn, utilizada para machine learning con algoritmos de clasificación o regresión, en nuestro caso usaremos el algoritmo de regresión. Para poder usarlo utilizamos la pérdida de cuantiles en lugar de la pérdida de mínimos cuadrados, esto se realiza modificando estos parámetros: “loss = quantile” donde se ha seleccionado la pérdida por cuantiles como antes se ha comentado, el parámetro “Alpha” donde introduciremos el cuantil a entrenar. Otros parámetros modificados de los valores predeterminados son: “max_depth” donde se modifica la profundidad máxima de los estimadores de regresión individuales que limita la cantidad de nodos en el árbol, hemos seleccionado un valor de 2 para reducir el tiempo de entrenamiento sin sacrificar buenas predicciones.

3.5. Validación del modelo

Una vez entrenado el modelo, deberemos validar si este arroja unos resultados correctos para nuestra aplicación. En nuestro caso, esta validación se realizará con el 30% de datos, antes clasificados como datos de validación.

Como estamos comparando dos modelos diferentes, nos ayudaremos, además de con gráficas comparativas, con métricas de error. Estas son comúnmente usadas en modelos de machine learning para establecer si son válidos o no.

Las métricas que se estudiarán son: error cuadrático medio (RMSE), error medio absoluto (MAE), Coverage probability (CP), Mean width percentage (MWP).

A continuación, se explicarán como se calcula cada métrica de error.

- **Raíz del Error cuadrático medio (RMSE):** Representa la raíz cuadrada del MSE o Error cuadrático medio, este error representa la raíz de la media de los errores al cuadrado entre los valores predichos y los valores reales. EL RMSE es siempre positiva y un valor de 0 representa una predicción perfecta. En nuestro caso se ha realizado con el valor real del viento y el cuantil 50.

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **Error medio absoluto (MAE):** Representa la media de los errores absolutos entre los valores predichos y los valores reales. El MAE es siempre positiva y cuanto menor sea el valor mejor será el modelo de predicción. En nuestro caso se ha realizado con el valor real del viento y el cuantil 50.

$$MAE = \frac{1}{N} \sum_{i=1}^n |y_i - \hat{y}_i|$$

En las próximas dos métricas de error se ha definido un intervalo de confianza para el cálculo, en este caso se harán entre el percentil 95 y el percentil 5.

- **Coverage probability (CP):** es la probabilidad de que en el intervalo de confianza antes definido se incluya el valor verdadero, en este caso, la velocidad de viento correcta. Esta medida nos da que confiable es el modelo, si el CP es bajo significa que el modelo no esta bien entrenado o que para la mayoría de los cuantiles no obtenemos unos valores correctos. Un valor máximo de 1 significa que el intervalo de confianza definido siempre contiene el verdadero valor de la velocidad de viento predicha.

$$CP = P(\theta \in I(X))$$

Donde: θ es el valor verdadero de viento, $I(X)$ es el intervalo de confianza definido y $P(\cdot)$ es la probabilidad de que suceda [28].

- **Mean width percentage (MWP):** es usado para medir el ancho del intervalo de predicción, cuanto más pequeño sea este valor, más preciso es el intervalo [29].

$$MWP = \left(\frac{Intervalo_{alto} - Intervalo_{bajo}}{|\hat{\theta}|} \right) \times 100$$

Una vez obtenidas las métricas de error de cada modelo se irá a la última parte de la validación, lo primero que hay que realizar, es elegir el modelo que arroja los mejores resultados, esto se realizará a través de las gráficas antes explicadas y con las métricas de error, poniendo más interés en esta última.

Cuando tengamos el modelo ya seleccionado, realizaremos una gráfica de densidad de probabilidad. Esto se realiza con la función de densidad de probabilidad.

El modelo de machine learning no puede directamente obtener la función de densidad de probabilidad, por tanto, para calcularla se utiliza la estimación de densidad por núcleos (KDE – Kernal density estimation), esto se realizará con la función “gaussian_kde” de la librería “scipy.stats”. Esta función genera N cuantiles igualmente espaciados y se calcula el KDE de cada uno. Uno de los parámetros más importantes de esta función es el ancho de banda (BW) ya que un BW demasiado elevado conlleva a un mal estudio y por tanto una mala representación y un BW demasiado bajo introduce demasiado ruido al estimador [30].

Capítulo 4

Resultados finales

En este capítulo se presentan y discuten los resultados obtenidos. Podemos dividir este capítulo en tres secciones, la primera mostraremos gráficamente las predicciones que han sido generadas por ambos modelos, comparándolos entre sí y con los valores de viento real para diferentes intervalos de tiempo. Posteriormente se compararán los dos modelos a través de las métricas de error explicadas en el punto 3.5, sacando conclusiones de cada resultado. Y finalmente se expondrán las gráficas de probabilidad de cada predicción, usando “Kernel density estimation”.

4.1. Comparación gráfica de la predicción con los valores reales de viento.

En este primer apartado, como hemos comentado antes, se compararán gráficamente los dos modelos entrenados con los valores reales de viento. Comenzaremos viendo las predicciones con diferentes valores de tiempo, viendo gráficamente lo que sucede si aumentamos este valor para cada modelo entrenado. Posteriormente se compararán, para el mismo tiempo de predicción, los dos modelos entrenados, viendo de manera visual cual de ellos arroja mejores resultados, posteriormente viendo la veracidad de estas conclusiones en los siguientes apartados.

Dado que se han entrenado 100 modelos, debido a que tenemos 100 cuantiles deberemos elegir cuales mostramos en las gráficas, un cuantil importante es el 50, ya que representa la mediana, es uno de los puntos más comunes de referencia para representar la predicción más probable, mostraremos también el cuantil 25 para representar las posibles tendencias hacia

valores bajos en la predicción y el 75 ya que representa las posibles tendencias hacia valores altos en la predicción.

Dado que es imposible representar gráficamente todo el espacio de tiempo que se ha utilizado para la validación, ya que es un 30 % de los datos desde 2010 hasta 2023, es decir, 4 años aproximadamente, se seleccionará un espacio de tiempo donde la actividad de viento sea elevada para poder ver si para extremos de viento los modelos arrojan buenos valores predichos.

También se mostrará el limite de viento extremo que se ha calculado como la media de la velocidad del viento mas dos veces la desviación estándar, obteniendo un valor de viento extremo para el punto seleccionado de 11.129816055297852

4.1.1. Comparación para el modelo 1 entrenado usando diferentes rangos de tiempo de predicción.

Comenzaremos visualizando los valores predichos de los cuantiles 25, 50 y 75 junto a los valores reales de la magnitud del viento con un tiempo de predicción de 1 hora.




Figura 13: Predicción de viento de 1 hora con el modelo 1.




Figura 14: Predicción de viento de 3 horas con el modelo 1.




Figura 15: Predicción de viento de 6 horas con el modelo 1.




Figura 16: Predicción de viento de 12 horas con el modelo 1.

Como podemos observar la predicción de viento en la figura 13 obtenemos unos buenos resultados para valores altos de velocidad de viento, cuando aumentamos la diferencia de tiempo de predicción vamos obteniendo peores resultados, viendo que los valores reales se acercan a diferentes cuantiles del 50, es decir, reduciendo la probabilidad de que haya un viento extremo cuando en los valores reales si lo hay.

4.1.2. Comparación para el modelo 2 entrenado usando diferentes rangos de tiempo de predicción.

El procedimiento será el mismo que en el punto 4.1.1 donde se visualizarán el cuantil 25, 50 y 75 y los valores reales de viento.




Figura 17: Predicción de viento de 1 hora con el modelo 2.




Figura 18: Predicción de viento de 3 horas con el modelo 2.




Figura 19: Predicción de viento de 6 horas con el modelo 2.




Figura 20: Predicción de viento de 12 horas con el modelo 2.

En ambos modelos obtenemos unos resultados parecidos visualmente, no obstante, estos resultados no nos indican que modelo predice mejor los vientos extremos, para comprobar cual es mejor, usaremos las métricas de error y graficas de probabilidad que posteriormente se expondrán.

4.1.3. Comparación entre el modelo 1 y 2 entrenado usando diferentes rangos de tiempo de predicción.

Ahora compararemos los dos modelos a la vez junto al valor real de la velocidad del viento, lo haremos con el cuantil 50 de ambos modelos que representan la mediana de la predicción. Al igual que he comentado antes, esta manera de comprobación es solo orientativa y posteriormente se darán conclusiones mas precisas de que modelo es más correcto.




Figura 21: Predicción de viento de 1 hora en el modelo 1 y 2.




Figura 22: Predicción de viento de 3 horas en el modelo 1 y 2.




Figura 23: Predicción de viento de 6 horas en el modelo 1 y 2.




Figura 23: Predicción de viento de 12 horas en el modelo 1 y 2.

Como podemos ver los resultados empeoran cuando aumentamos la diferencia de tiempo de predicción, si observamos la diferencia entre los dos modelos, vemos que obtenemos resultados parecidos, pudiendo predecir valores correctos para velocidades bajas, pero prediciendo valores incorrectos para velocidades por encima del límite de viento extremo.

4.2. Métricas de error del modelo 1 y el modelo 2.

En este apartado compararemos las métricas de error, explicadas en el punto 3.5, de los modelos 1 y 2 para diferentes rangos de tiempo de predicción.

Métricas de error	Modelo 1 (+1)	Modelo 2 (+1)
MAE	0.4543	0.4811
RMSE	0.6447	0.6784
CP	0.8679	0.8802
MWP	0.3445	0.3768

Tabla 3: Metricas de error para el modelo 1 y 2 en un rango de 1 hora de predicción.

Métricas de error	Modelo 1 (+3)	Modelo 2 (+3)
MAE	0.9040	0.9548
RMSE	1.2006	1.2681
CP	0.8782	0.8871
MWP	0.7043	0.7473

Tabla 4: Metricas de error para el modelo 1 y 2 en un rango de 3 horas de predicción.

Métricas de error	Modelo 1 (+6)	Modelo 2 (+6)
MAE	1.2241	1.2773
RMSE	1.5939	1.6561
CP	0.8756	0.89
MWP	0.9402	1.0134

Tabla 5: Metricas de error para el modelo 1 y 2 en un rango de 6 horas de predicción.

Métricas de error	Modelo 1 (+12)	Modelo 2 (+12)
MAE	1.6259	1.6234
RMSE	2.0669	2.0745
CP	0.8769	0.9006
MWP	1.2178	1.3125

Tabla 6: Metricas de error para el modelo 1 y 2 en un rango de 12 horas de predicción.

Empezaremos comentando la métrica de error MAE para diferentes tiempos de predicción, en la tabla 3 (tiempo de predicción de 1 hora) observamos en ambos modelos un MAE bajo, esto implica que las predicciones realizadas con el percentil 50 están cerca de los valores reales de la velocidad de viento. Cuando vamos aumentando el tiempo de predicción vemos que el MAE va aumentando lo que supone un peor modelo de predicción. Si comparamos ambos modelos en todas las tablas, observamos que el MAE es ligeramente mejor en el modelo 1 que en el modelo 2, lo que supone que el modelo 1 es mejor con respecto al percentil 50, esto no quiera decir que el modelo completo sea mejor, para eso estudiaremos a continuación las demás métricas de error.

El RMSE es mejor cuando el valor es bajo, ya que indica que los errores grandes son menos frecuentes, esto es debido a que al estar al cuadrado la media de los errores se penalizan más los valores grandes, es decir, ante un cambio ligero en los errores puede causar una variación grande en el RMSE. Si observamos las tablas, ante un tiempo de predicción de 1 hora obtenemos un valor bajo, aumentando este valor cuanto más aumentamos el tiempo de predicción, como sucede con el MAE. En este caso, el aumento es más grande, debido al cuadrado de la formula explicada anteriormente.

Con respecto al CP y al MWP ambos han sido estudiados para un intervalo de confianza entre el percentil 95 y el percentil 5, en el caso del CP, el valor se mantiene prácticamente constante en 0.87, esto quiere decir que, en promedio, el intervalo de confianza contiene el valor correcto de predicción de viento el 87 % de las veces, algo razonable para la aplicación que estamos tratando. En este caso el modelo 2 arroja mejores valores de CP que el modelo 1 concluyendo que, dentro del intervalo de confianza definido, el modelo 2 obtiene mayor porcentaje de acierto dentro de dicho intervalo.

El MWP si varia con respecto a que intervalo de tiempo estemos prediciendo, empezamos con los valores para un intervalo de 1 hora, obteniendo valores entre 0.34 y 0.37 en los dos modelos, lo que supone que la incertidumbre sobre la velocidad del viento es baja y el intervalo de confianza definido es preciso. El MWP va aumentando cuanto más aumentamos el tiempo de predicción, hasta conseguir un valor de entre 1.21 a 1.31 para el intervalo de 12 horas de predicción, este valor es mayor que la propia estimación (121 % del valor estimado) lo que indica que la incertidumbre es bastante alta. En este caso el modelo 1 arroja mejores resultados que el modelo 2.

Concluyendo que en el intervalo de tiempo de 1 hora obtenemos unos buenos resultados para ambos modelos y cuando vamos aumentando la diferencia de tiempo de predicción ambos modelos arrojan valores de velocidad de viento predichos peores, algo lógico al no tener valores de las variables predictoras recientes.

Con respecto a la comparación de ambos modelos, son prácticamente parecidos, arrojando el modelo 1 mejores resultados en prácticamente todas las métricas de error. Para

los tres primeros intervalos de tiempo (1, 3 y 6 horas) el modelo 1 obtiene mejores resultados exceptuando la métrica de error CP en donde el modelo 2 es ligeramente mejor, con respecto al ultimo estudio con un intervalo de tiempo de 12 horas los modelos 1 y 2 son prácticamente iguales, arrojando los dos modelos valores poco fiables.

Por tanto, para el siguiente apartado se estudiará solo el modelo 1, debido a que las métricas de error son mejores en prácticamente todos los intervalos de tiempo, además una razón extra por la que se elige este modelo es porque en el proceso de entrenamiento el modelo 1 tardó una media de 10 minutos y el modelo 2 tardó una media de 6 horas. Esta diferencia de tiempo de entrenamiento puede ser interesante si queremos reentrenar el modelo con nuevos datos de predicción, por tanto, el modelo 1 es más eficiente.

4.3. Función de densidad de probabilidad y KDE

En este último apartado de este capítulo, se evaluará las curvas de densidad de probabilidad del modelo 1, elegido en el punto anterior 4.2, para los 4 intervalos de tiempo de predicción, usando 3 muestras diferentes para cada caso, una en la que tengamos una velocidad baja, otra en la que tengamos una velocidad media y la ultima muestra donde se tenga una velocidad alta.

Como hemos comentado anteriormente en el punto 3.5 el ancho de banda es un parámetro de la función de gran importancia, por tanto, debe tener un valor que arroje graficas correctas sin ruido para ello valores cercanos al 0 y superiores a 1 se descartan. La función tiene un valor predeterminado llamado “scotts factor”, en nuestro caso este facto toma un valor aproximado de 0.7 por tanto usaremos ese para la curva de densidad de probabilidad.

Las 3 muestras que se han seleccionado son: 200 para una velocidad baja de viento, 390 para una velocidad media de viento y 1305 para una velocidad alta de viento.

En la gráfica también se mostrará el umbral del viento extremo antes calculado y el área a la derecha del umbral, este valor será útil posteriormente para conocer la probabilidad de que haya viento extremo.

Para un intervalo de 1 hora obtenemos las siguientes graficas para las 3 muestras seleccionadas:




Figura 24: Curva de densidad de probabilidad para la muestra 200 con un intervalo de +1 hora.




Figura 25: Curva de densidad de probabilidad para la muestra 390 con un intervalo de +1 hora.




Figura 26: Curva de densidad de probabilidad para la muestra 1305 con un intervalo de +1 hora.

Como podemos observar la primera curva sigue una distribución gamma, es decir sesgada hacia la derecha o asimétrica hacia la izquierda. La segunda curva sigue una

distribución prácticamente normal con una asimetría leve hacia la derecha. Por último, la figura 26 sigue una distribución sesgada a la izquierda con cola larga a la izquierda.

Seguimos observando las curvas de densidad de probabilidad para el intervalo de predicción de 3 horas.




Figura 27: Curva de densidad de probabilidad para la muestra 200 con un intervalo de +3 horas.




Figura 28: Curva de densidad de probabilidad para la muestra 390 con un intervalo de +3 horas.





Figura 29: Curva de densidad de probabilidad para la muestra 1305 con un intervalo de +3 horas.

Como podemos observar, al aumentar el intervalo de tiempo obtenemos una distribución t de student donde aumenta los valores laterales cómo se puede en las figuras 28 y 29 esto es debido a que el modelo es peor cuanto más aumentamos el intervalo de tiempo.

Para el intervalo de tiempo de predicción de 6 y 12 horas se pondrá menos atención en las gráficas, debido a que, como es lógico obtendremos unos valores aun peores, obteniendo curvas con distribuciones más uniformes, obteniendo valores de pico menores, es decir obteniendo menos probabilidad para cada predicción. Estas gráficas se representarán juntas.

(a)



(b)




Figura 30: Curvas de densidad de probabilidad para las tres muestras seleccionadas con un intervalo de 6 horas (a) y con un intervalo de 12 horas (b).

Como podemos observar en la figura 30, las curvas van disminuyendo el área bajo la curva lo que supone menos acierto en la predicción cuando aumentamos el intervalo de tiempo, haciendo que las curvas se alejen de una distribución normal.

Para terminar los resultados finales, se realizará la función “gaussian_kde” para todos los periodos, es decir, para todas las muestras, también se obtendrá el área que queda a la derecha del umbral de viento extremo y la curva de densidad de probabilidad, esta área representa la probabilidad de que haya viento extremo en cada muestra y se calcula con la función “integrate_box_1d” de la librería “scipy” que calcula la integral de la curva a la derecha del umbral de viento extremo.

Con la probabilidad de que haya viento extremo devuelta por el modelo podremos compararla con el valor real del modelo, esto se hará de la siguiente manera. Primero calcularemos el KDE de todas las muestras, después calcularemos el área bajo la curva, es decir, la probabilidad de que haya un viento extremo en cada muestra. Con esto obtendremos el siguiente dataframe:

	valor_real	valor_quantil_50	probabilidad_viento_extremo
0	9.067293	8.472960	0.0
1	8.821928	8.505190	0.0
2	8.776106	8.193419	0.0
3	8.489281	7.666813	0.0
4	7.906375	7.815011	0.0
...	...	...	...
36809	6.555438	6.782603	0.0
36810	6.802301	6.847800	0.0
36811	7.034113	6.748175	0.0
36812	6.817901	6.393548	0.0
36813	6.489384	6.211544	0.0

36814 rows × 3 columns

Figura 31: dataframe con el valor real, valor del cuantil 50 y la probabilidad de viento extremo calculada

Como podemos observar obtenemos los 3 valores para las 36814 muestras.

Posteriormente, se hará una función donde muestra a muestra se compruebe si el valor real de viento del dataframe de la figura 31 está por encima o por debajo del umbral de viento extremo establecido, poniendo en el dataframe un 1 si el valor real está por encima y un 0 si el valor real está por debajo.

Con esto crearemos otro dataframe que consistirá en un índice llamado extreme prob donde se mostrarán las probabilidades de que suceda un viento extremo, es decir, un índice del 0 al 100 idealmente (en nuestro caso tendremos un índice del 0 al 96, debido a que probabilidades

superiores a 96 no existen en nuestro modelo). Este dataframe contará de tres columnas, el total de casos para cada probabilidad, los casos extremos que ha habido en cada total de casos y por último el porcentaje de probabilidad arrojado por el modelo. Esta última columna calculada como los casos extremos entre el total de casos por 100. Con esto conseguimos el siguiente dataframe.

	Total casos	Casos extremos	Porcentaje
Extreme prob			
0.0	33732	12	0.035575
1.0	164	6	3.658537
2.0	212	5	2.358491
3.0	142	4	2.816901
4.0	99	7	7.070707
...	...	...	...
92.0	39	35	89.743590
93.0	71	64	90.140845
94.0	133	131	98.496241
95.0	61	60	98.360656
96.0	396	389	98.232323

97 rows × 3 columns

Figura 32: Dataframe con total casos, casos extremos y porcentaje.

Para representar estos valores utilizaremos un gráfico de dispersión para conocer la relación entre las dos variables con la función de Python “scatter”. En el eje x visualizaremos el índice del dataframe de la figura 32 y en el eje y visualizaremos el porcentaje, obteniendo entre las dos la relación que hay. Para comprobar que el modelo obtiene valores correctos de predicción visualizaremos en la misma gráfica la línea de regresión y la siguiente ecuación:

$$y = mx + b$$

Donde m es la pendiente y b es la intersección con el eje y

También visualizaremos el coeficiente de correlación entre la x y la y de la gráfica para de manera estadística conocer si los resultados son buenos.

Comenzamos viendo el grafico de dispersión para un intervalo de tiempo de predicción de 1 hora.




Figura 33: Grafica de dispersión para un intervalo de tiempo de 1 hora con ecuación y coeficiente de correlación




Figura 34: Grafica de dispersión para un intervalo de tiempo de 3 horas con ecuación y coeficiente de correlación




Figura 35: Grafica de dispersión para un intervalo de tiempo de 6 horas con ecuación y coeficiente de correlación




Figura 36: Grafica de dispersión para un intervalo de tiempo de 12 horas con ecuación y coeficiente de correlación

Como podemos observar en las gráficas de dispersión, los 4 ensayos arrojan prácticamente una línea recta, es decir, una pendiente igual a 1, con coeficiente de correlación similares, siendo ligeramente superiores en el caso de los intervalos de tiempo de 1 y 3 horas, este valor cercano al 1, indica que los valores están correlacionados, por tanto, el valor arrojado por el modelo es el mismo que el valor real.

Si observamos para intervalos más superiores, las probabilidades que muestra el modelo se reducen, llegando al 60 en el caso del intervalo de tiempo de 12 horas, esto significa que el modelo ante ese intervalo no puede ofrecer más probabilidad de que haya viento extremo o no.

En conclusión, obtenemos muy buenos resultados para intervalos de tiempo pequeños, de 1 a 3 horas, siendo muy eficaces y dando probabilidades correctas de viento extremo, y peores resultados, pero aceptables, para intervalos de tiempo superiores, de 6 a 12 horas.

Capítulo 5

Conclusiones

Como hemos podido ver en los capítulos anteriores y en especial atención en el capítulo de resultados finales, el potencial del Machine Learning para la predicción de viento es enorme. Hemos obtenido los resultados esperados para ambos modelos, viendo primeramente que ambos pueden predecir el viento con un porcentaje de error pequeño, posteriormente viendo que se obtienen métricas de error correctas para ambos modelos. Y finalmente estudiando más en profundidad el modelo 1, en el punto 4.3, obteniendo unos resultados correctos de probabilidad de que ocurra un viento extremo.

También hemos podido observar que el aumento de los intervalos de tiempo aumenta el error de predicción y hace que las probabilidades de que haya viento extremo bajen, haciendo el modelo menos fiable, esto puede ser debido a la incertidumbre y al rápido cambio de algunas variables predictoras en cuestión de horas.

El objetivo de este trabajo fin de grado fue desde un principio crear un sistema de alertas de viento extremo, para que tanto operadores de la red eléctrica como empresas de energía eólica pudiesen comprobar si para un intervalo de tiempo de 1 a 12 horas habría viento extremo o no. Este trabajo ha cumplido con el objetivo, además añadiendo un valor a la probabilidad de que ocurra un viento extremo en el intervalo de tiempo seleccionado, parte crucial para la gestión de los parques eólicos, siendo de gran utilidad para los profesionales antes señalados.

En conclusión, los dos modelos entrenados de machine learning para predecir viento extremo son útiles para dicho fin, habiendo obtenido resultados razonables para los 4 intervalos de tiempo. Debido a que estos modelos son más efectivos en tiempos de predicción cortos, se pueden emplear en sistemas de alertas para asegurar los aerogeneradores de las plantas eólicas, pero también, indirectamente para conocer si se podrá volcar o no energía a la red eléctrica

Capítulo 6

Bibliografía

- [1] Orús, A. (2024, 18 de marzo). «Las energías renovables en España.» [En línea]. Disponible en: <https://es.statista.com/temas/6675/las-energias-renovables-en-espana/#editorsPicks> [Último acceso 16/07/2024]
- [2] Molina Hernández Letsy Adilene. (2015, junio 18). «Impacto ambiental por la explotación de recursos naturales». [En línea]. Disponible en: <https://www.gestiopolis.com/impacto-ambiental-por-la-explotacion-de-recursos-naturales/> [Último acceso 16/07/2024]
- [3] Abigail Orús. (2024, mayo 22). «Producción de energía eléctrica distribuida por tecnología en España en 2023». [En línea]. Disponible en: <https://es.statista.com/estadisticas/993747/porcentaje-de-la-produccion-de-energia-electrica-por-fuentes-energeticas-en-espana/> [Último acceso 16/07/2024]
- [4] «La eólica en España», Asociación Empresarial Eólica. [En línea]. Disponible en: <https://aeolica.org/sobre-la-eolica/la-eolica-en-espana/> [Último acceso 16/07/2024]
- [5] «Energía Eólica: qué es, cómo funciona y sus tipos», REPSOL. [En línea]. Disponible en: <https://www.repsol.com/es/energia-futuro/futuro-planeta/energia-eolica/index.cshtml> [Último acceso 19/07/2024]
- [6] «Edibon», Edibon. [En línea]. Disponible en: <https://www.edibon.com/es/blog/como-funciona/que-significa-dfig> [Último acceso 19/07/2024]
- [7] M. López, D. Barrero, y S. Garzon, «Sistema de Control para Aerogeneradores Empleando Lógica Difusa», Diful00ci@ Revista en Ingeniería y Tecnología, UAZ, vol. 8, p. 1, abr. 2015.
- [8] «¿Que es la Energía Eólica? – Centro de Investigacion en Recursos Energéticos y Sustentables». [En línea]. Disponible en: <https://www.uv.mx/coatza/cires/main/keeseolica/#> [Último acceso 21/07/2024]

- [9] «Gamesa G106/2500 - Fabricantes y aerogeneradores - Acceso en línea - The Wind Power». [En línea]. Disponible en: https://www.thewindpower.net/turbine_es_992_gamesa_g106-2500.php [Ultimo acceso 21/07/2024]
- [10] «Qué es la Inteligencia Artificial». [En línea]. Disponible en: <https://planderecuperacion.gob.es/noticias/que-es-inteligencia-artificial-ia-prtr> [Ultimo acceso 26/07/2024]
- [11] I. CORPORATIVA, «Descubre los principales beneficios del Machine Learning», Iberdrola. [En línea]. Disponible en: <https://www.iberdrola.com/innovacion/machine-learning-aprendizaje-automatico> [Ultimo acceso 26/07/2024]
- [12] «La historia del machine learning desde sus comienzos | Tokio», Tokio School. [En línea]. Disponible en: <https://www.tokioschool.com/noticias/historia-machine-learning/> [Ultimo acceso 26/07/2024]
- [13] D. Hinestroza Ramírez, “El machine learning a través de los tiempos, y los aportes a la humanidad,” 2018.
- [14] «Qué es Prueba de Turing Concepto y definición. Glosario». [En línea]. Disponible en: <https://gamco.es/glosario/prueba-de-turing/> [Ultimo acceso 29/07/2024]
- [15] «Prueba de Turing», Wikipedia, la enciclopedia libre. 8 de julio de 2024. [En línea]. Disponible en: https://es.wikipedia.org/w/index.php?title=Prueba_de_Turing&oldid=161197533#CITAREFSaygin2000 [Ultimo acceso 29/07/2024]
- [16] «Azure Machine Learning - ML as a Service | Microsoft Azure». [En línea]. Disponible en: <https://azure.microsoft.com/en-us/products/machine-learning> [Ultimo acceso 30/07/2024]
- [17] P. P. Shinde y S. Shah, «A Review of Machine Learning and Deep Learning Applications», en 2018 Fourth International Conference on Computing Communication Control and Automation (ICCUBEA), ago. 2018, pp. 1-6. doi: 10.1109/ICCUBEA.2018.8697857.
- [18] «¿Qué es el aprendizaje supervisado? | IBM». [En línea]. Disponible en: <https://www.ibm.com/es-es/topics/supervised-learning> [Ultimo acceso 30/07/2024]
- [19] «Aprendizaje Supervisado», CIIA. [En línea]. Disponible en: <https://www.ciiia.mx/noticiasciiia/aprendizaje-supervisado-1> [Ultimo acceso 30/07/2024]

[20] decide4AI, «Tipos de aprendizaje que usan los algoritmos de Machine Learning», Decide. [En línea]. Disponible en: <https://decidesoluciones.es/tipos-de-aprendizaje-algoritmos-machine-learning/> [Ultimo acceso 30/07/2024]

[21] «¿Qué es el aprendizaje semisupervisado? | IBM». [En línea]. Disponible en: <https://www.ibm.com/es-es/topics/semi-supervised-learning> [Ultimo acceso 30/07/2024]

[22] R. Koenker, Quantile Regression. Cambridge University Press, 2005.

[23] Z. Zhang et al., «Wind speed forecasting based on Quantile Regression Minimal Gated Memory Network and Kernel Density Estimation», Energy Conversion and Management, vol. 196, pp. 1395-1409, sep. 2019, doi: 10.1016/j.enconman.2019.06.024.

[24] C3S, «ERA5 hourly data on single levels from 1940 to present». Copernicus Climate Change Service (C3S) Climate Data Store (CDS), 2018. doi: 10.24381/CDS.ADBB2D47.

[25] «Península ibérica», Wikipedia, la enciclopedia libre. Accedido: 13 de agosto de 2024. [En línea]. Disponible en: https://es.wikipedia.org/w/index.php?title=Pen%C3%ADnsula_ib%C3%A9rica&oldid=161663321 [Ultimo acceso 13/08/2024]

[26] «Arcotangente de dos parámetros», Wikipedia, la enciclopedia libre. 28 de junio de 2024. [En línea]. Disponible en: https://es.wikipedia.org/w/index.php?title=Arcotangente_de_dos_par%C3%A1metros&oldid=161002362 [Ultimo acceso 15/08/2024]


[27] P. y Estadística, «▷ Coeficiente de correlación de Pearson», Probabilidad y Estadística. [En línea]. Disponible en: <https://www.probabilidadyestadistica.net/coeficiente-de-correlacion-de-pearson/> [Ultimo acceso 10/09/2024]

[28] G. Casella y R. L. Berger, *Statistical Inference*, 2nd ed. Belmont, CA, USA: Duxbury Press, 2002.

[29] H. Bai, G. Li, C. Liu, B. Li, Z. Zhang, y H. Qin, «Hydrological probabilistic forecasting based on deep learning and Bayesian optimization algorithm», Hydrology Research, vol. 52, jul. 2021, doi: 10.2166/nh.2021.161.

[30] C. Tenreiro, «Fourier series-based direct plug-in bandwidth selectors for kernel density estimation», Journal of Nonparametric Statistics, vol. 23, n.º 2, pp. 533-545, jun. 2011, doi: 10.1080/10485252.2010.537337.

Universidad de Alcalá
Escuela Politécnica Superior



ESCUELA POLITECNICA
SUPERIOR



Universidad
de Alcalá